

Comparação entre amostragem aleatória simples e amostragem estratificada aplicada às despesas administrativas partidárias

Nicolas Rodrigues de Oliveira

PPCA - UNB

Brasília, Brasil

nk.oliveira@gmail.com

Abstract—Os partidos políticos desempenham papel central nos sistemas democráticos e administram volumes significativos de recursos públicos e privados. No Brasil, a disponibilização de dados financeiros abertos pelo Tribunal Superior Eleitoral (TSE) amplia as possibilidades de análise estatística sobre transparência pública, financiamento político e comportamento organizacional. Entretanto, a elevada heterogeneidade das finanças partidárias dificulta a obtenção de estimativas precisas por métodos tradicionais de amostragem.

Este trabalho propõe a aplicação e comparação de técnicas de amostragem e estimação para análise das despesas administrativas de partidos políticos brasileiros utilizando dados financeiros do TSE referentes ao exercício de 2025. O estudo avalia ganhos de precisão obtidos por meio da amostragem estratificada proporcional e do uso do estimador razão. A variável principal de interesse corresponde à despesa administrativa total dos partidos políticos, enquanto a receita total partidária é utilizada como variável auxiliar devido à esperada correlação positiva entre arrecadação e despesas.

O pipeline analítico foi desenvolvido em Python utilizando tecnologias open source para ingestão, pré-processamento, enriquecimento e modelagem dos dados. As bases de receitas e despesas partidárias foram integradas a informações auxiliares do Cadastro Nacional da Pessoa Jurídica (CNPJ), permitindo a construção de indicadores financeiros voltados à inferência estatística. O software Jamovi foi utilizado como apoio complementar às análises estatísticas.

Como resultados esperados, busca-se observar redução da variância e do erro de estimação em comparação com abordagens de amostragem aleatória simples, contribuindo para avaliação de estratégias estatísticas mais eficientes aplicadas à análise financeira partidária. O estudo também busca fornecer uma estrutura analítica reproduzível para futuras pesquisas relacionadas à transparência eleitoral e análise estatística de dados políticos.

Index Terms—Amostragem Estratificada, Estimador Razão, Finanças Partidárias, TSE, Dados Abertos Governamentais, Estimação Estatística, Transparência Pública, Despesas Administrativas, Python, Pesquisa Reprodutível, Jamovi.

I. INTRODUÇÃO

Os partidos políticos brasileiros administram anualmente volumes expressivos de recursos públicos e privados destinados à manutenção de atividades administrativas, institucionais e eleitorais. A crescente disponibilização de bases abertas de prestação de contas pelo Tribunal Superior Eleitoral (TSE) ampliou significativamente as possibilidades de investigação

quantitativa relacionadas à transparência pública, financiamento político e comportamento organizacional partidário [1].

Dentre as bases disponibilizadas pelo TSE encontram-se registros individualizados de receitas e despesas declaradas por diretórios nacionais, estaduais e municipais. Para o exercício de 2025, os dados contemplam informações relacionadas a arrecadações, transferências partidárias, despesas administrativas e pagamentos realizados a fornecedores [2]–[4].

Entretanto, a estrutura financeira dos partidos políticos brasileiros apresenta elevada heterogeneidade. Enquanto algumas legendas concentram grandes volumes de arrecadação e despesas, outras operam com estruturas significativamente menores. Essa assimetria tende a produzir elevada dispersão estatística, dificultando a obtenção de estimativas precisas quando se utilizam métodos tradicionais de amostragem aleatória simples.

Nesse contexto, técnicas de amostragem estratificada e estimadores auxiliares apresentam potencial para aumentar a eficiência estatística das estimativas populacionais. A utilização de variáveis auxiliares correlacionadas com a variável de interesse pode contribuir para redução da variância e melhoria da precisão inferencial. Apesar da crescente disponibilidade de dados financeiros partidários em formatos abertos, ainda são limitados os estudos que aplicam formalmente técnicas de inferência estatística e amostragem estratificada sobre bases financeiras partidárias brasileiras.

Diante desse cenário, este trabalho propõe a aplicação e comparação de diferentes estratégias de inferência estatística utilizando dados financeiros partidários do TSE referentes ao exercício de 2025. A variável principal de interesse corresponde à despesa administrativa total dos partidos políticos, enquanto a receita total partidária é utilizada como variável auxiliar devido à expectativa de correlação positiva entre arrecadação e despesas administrativas.

A proposta metodológica contempla a comparação entre diferentes estratégias de amostragem e estimação, incluindo:

- amostragem aleatória simples;
- amostragem estratificada proporcional;
- estimador razão;

O objetivo central consiste em avaliar os ganhos de precisão obtidos por meio da estratificação e do uso de variáveis auxiliares na estimação de indicadores financeiros partidários.

Além da contribuição metodológica relacionada à teoria de amostragem, o estudo também busca construir uma estrutura analítica reprodutível para tratamento e modelagem de dados financeiros partidários utilizando tecnologias de código aberto.

A. Transparência Pública e Dados Abertos

A transparência pública constitui um dos principais mecanismos de fortalecimento institucional e controle social em regimes democráticos. O avanço das políticas de governo aberto e a ampliação da disponibilização de dados governamentais em formatos estruturados têm possibilitado maior fiscalização das ações do Estado, além de favorecer o desenvolvimento de pesquisas quantitativas aplicadas à administração pública e à ciência política [5].

No Brasil, a Lei nº 12.527/2011 (Lei de Acesso à Informação) consolidou instrumentos voltados à transparência ativa e ao acesso público a informações produzidas pela administração pública [5]. A partir desse contexto institucional, diferentes órgãos governamentais passaram a disponibilizar bases abertas relacionadas à execução orçamentária, transferências governamentais, dados eleitorais e financiamento político.

No âmbito eleitoral, o Tribunal Superior Eleitoral disponibiliza conjuntos de dados relacionados a candidaturas, resultados eleitorais, prestação de contas eleitorais e contas partidárias por meio de seu Portal de Dados Abertos [1]. Essas bases possuem elevada granularidade analítica e permitem investigações relacionadas à transparência financeira, comportamento organizacional partidário e financiamento político.

A disponibilização de bases estruturadas também favorece a aplicação de técnicas estatísticas e ferramentas computacionais voltadas ao processamento e análise de grandes volumes de dados públicos. Entretanto, trabalhos envolvendo dados governamentais frequentemente enfrentam desafios relacionados à padronização, integração e qualidade das informações, exigindo procedimentos adicionais de tratamento e pré-processamento analítico.

Além disso, o uso de dados abertos governamentais contribui para o fortalecimento da reprodutibilidade científica, permitindo auditoria metodológica, replicação de resultados e desenvolvimento de pesquisas quantitativas baseadas em evidências públicas.

B. Finanças Partidárias

As finanças partidárias brasileiras envolvem a movimentação de recursos públicos e privados destinados à manutenção das atividades administrativas, institucionais e eleitorais dos partidos políticos. O financiamento partidário possui papel relevante na dinâmica política nacional, influenciando estruturas organizacionais, capacidade operacional e competitividade eleitoral das legendas.

Estudos relacionados ao financiamento político brasileiro apontam elevada concentração de recursos financeiros entre partidos de maior porte, refletindo desigualdades estruturais no sistema partidário nacional [6], [7]. Segundo Braga e Bourdoukan [7], o fortalecimento do financiamento público

ampliou a dependência partidária em relação aos recursos provenientes do Fundo Partidário e, posteriormente, do Fundo Especial de Financiamento de Campanha (FEFC).

Além dos aspectos administrativos e eleitorais, o financiamento político também possui relevância institucional. Speck [8] argumenta que os mecanismos de financiamento partidário e eleitoral podem influenciar relações entre interesses públicos e privados, tornando a transparência financeira elemento importante para fortalecimento democrático e mitigação de riscos associados à corrupção política.

O Tribunal Superior Eleitoral disponibiliza registros detalhados de receitas e despesas partidárias por meio das bases de prestação de contas anuais [2]–[4]. Essas bases incluem informações relacionadas a arrecadações, transferências financeiras, pagamentos realizados, fornecedores, documentos fiscais e classificações de despesas declaradas pelos partidos políticos.

A elevada granularidade dessas informações possibilita análises quantitativas voltadas à identificação de padrões financeiros, comportamento de gastos e estrutura administrativa partidária. Entretanto, as bases também apresentam forte heterogeneidade financeira entre partidos políticos, uma vez que algumas legendas concentram grandes volumes de arrecadação e despesas, enquanto outras operam com estruturas significativamente menores.

Essa heterogeneidade tende a produzir distribuições assimétricas e elevada dispersão estatística nos indicadores financeiros partidários, dificultando a obtenção de estimativas precisas quando se utilizam métodos tradicionais de inferência baseados em amostragem aleatória simples. Nesse contexto, técnicas de estratificação e estimadores auxiliares surgem como alternativas relevantes para aumento da eficiência estatística das estimativas populacionais.

C. Problema de Pesquisa

Considerando a elevada heterogeneidade financeira observada entre os partidos políticos brasileiros, este trabalho investiga se técnicas de amostragem estratificada e estimadores auxiliares podem produzir estimativas mais eficientes das despesas administrativas partidárias quando comparadas à amostragem aleatória simples.

A pesquisa busca responder principalmente às seguintes questões:

- a estratificação por porte financeiro reduz a variância das estimativas populacionais?
- a utilização da receita total partidária como variável auxiliar melhora a precisão inferencial das estimativas de despesas administrativas?
- quais estratégias amostrais apresentam melhor desempenho estatístico em cenários caracterizados por elevada dispersão financeira?

A partir dessas questões, o estudo procura contribuir para aplicação de técnicas clássicas de inferência estatística em bases abertas eleitorais, integrando métodos quantitativos, transparência pública e análise financeira partidária em uma estrutura analítica reprodutível.

II. REFERENCIAL TEÓRICO

A teoria de amostragem constitui um dos principais fundamentos da inferência estatística, permitindo estimar parâmetros populacionais a partir da observação de subconjuntos representativos da população [9]–[11]. Em contextos nos quais levantamentos censitários apresentam elevado custo operacional, computacional ou temporal, técnicas amostrais tornam-se alternativas relevantes para obtenção de estimativas eficientes e operacionalmente viáveis.

No contexto deste trabalho, a população de interesse é composta pelos partidos políticos brasileiros com registros financeiros disponíveis nas bases de prestação de contas anuais do Tribunal Superior Eleitoral referentes ao exercício de 2025. Para fins inferenciais, adotou-se como unidade amostral básica o partido político agregado no nível anual de observação, permitindo consolidar receitas e despesas partidárias em uma única unidade analítica associada a cada legenda, conforme representado por:

Partido Político $\times$ Ano

Essa estratégia de agregação busca reduzir a variabilidade transacional presente nos registros individuais de receitas e despesas, além de facilitar procedimentos de estratificação e análise comparativa entre partidos políticos.

Considere uma população finita composta por N unidades, da qual é selecionada uma amostra aleatória de tamanho n . Nesse contexto, o estimador da média amostral pode ser definido por:

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i \quad (1)$$

em que y_i representa o valor observado para a unidade i . A precisão da estimativa depende diretamente da variabilidade populacional, do tamanho da amostra e do desenho amostral adotado [9], [10].

Nas bases financeiras partidárias, espera-se elevada heterogeneidade entre partidos políticos em termos de arrecadação, despesas e estrutura administrativa. Essa característica tende a aumentar a dispersão estatística dos indicadores financeiros analisados, tornando relevante a utilização de técnicas inferenciais capazes de reduzir a variância das estimativas.

A. Amostragem Estratificada

A amostragem estratificada consiste na divisão da população em grupos relativamente homogêneos, denominados estratos, seguida da seleção de amostras independentes dentro de cada grupo [12]. O objetivo principal da estratificação é reduzir a variabilidade interna dos estratos e aumentar a precisão das estimativas populacionais.

A média estratificada pode ser representada por:

$$\bar{y}_{st} = \sum_{h=1}^L W_h \bar{y}_h \quad (2)$$

em que:

- L representa o número de estratos;
- $\bar{y}_h$ corresponde à média amostral do estrato h ;
- $W_h = N_h/N$ representa o peso do estrato na população total.

Segundo Cochran [9], a amostragem estratificada tende a produzir ganhos significativos de precisão quando existe elevada heterogeneidade entre estratos e relativa homogeneidade interna em cada grupo.

Neste estudo, considera-se que partidos políticos com características financeiras semelhantes podem ser agrupados em estratos baseados em porte econômico ou receita total, reduzindo a dispersão interna observada nos dados financeiros partidários.

B. Estimadores Auxiliares

Estimadores auxiliares utilizam informações adicionais conhecidas sobre a população com o objetivo de melhorar a eficiência inferencial. Quando existe correlação entre a variável de interesse Y e uma variável auxiliar X , torna-se possível reduzir o erro de estimação incorporando essa relação ao processo estatístico [10].

O estimador razão é definido por:

$$\hat{Y}_R = X \frac{\bar{y}}{\bar{x}} \quad (3)$$

em que X representa o total populacional conhecido da variável auxiliar.

Segundo Lohr [10], estimadores auxiliares tendem a apresentar melhor desempenho quando existe associação significativa entre as variáveis analisadas.

Neste trabalho, a receita total partidária é utilizada como variável auxiliar para estimação das despesas administrativas dos partidos políticos, considerando a expectativa de correlação positiva entre arrecadação e estrutura de gastos administrativos observada nas bases financeiras disponibilizadas pelo Tribunal Superior Eleitoral.

III. TRABALHOS RELACIONADOS

Pesquisas relacionadas à transparência pública, financiamento político e análise quantitativa de dados eleitorais tiveram seu potencial analítico ampliado nos últimos anos, especialmente após o avanço das políticas de dados abertos governamentais no Brasil.

No contexto da transparência pública, a disponibilização de bases abertas por órgãos governamentais ampliou significativamente as possibilidades de controle social, fiscalização institucional e desenvolvimento de pesquisas quantitativas aplicadas à administração pública. A Lei de Acesso à Informação consolidou mecanismos voltados à transparência ativa e ao acesso público a informações governamentais [5]. Em complemento, o Portal de Dados Abertos do Tribunal Superior Eleitoral disponibiliza bases estruturadas relacionadas a candidaturas, resultados eleitorais e prestações de contas partidárias [1].

Embora a abertura de dados públicos tenha favorecido o desenvolvimento de análises quantitativas mais robustas, estudos envolvendo dados governamentais frequentemente enfrentam

desafios relacionados à padronização, integração, completude e qualidade das informações disponibilizadas. Essas limitações podem impactar diretamente a construção de indicadores estatísticos e a confiabilidade das estimativas produzidas.

No campo das finanças partidárias, Braga e Bourdoukan [7] discutem a relação entre organização partidária, competição eleitoral e financiamento público no sistema político brasileiro, destacando a crescente relevância dos recursos públicos para manutenção das estruturas partidárias. De forma complementar, Bolognesi e Cervi [6] analisam o perfil do financiamento partidário brasileiro, evidenciando diferenças estruturais relevantes entre partidos em termos de arrecadação, objetivos organizacionais e capacidade financeira.

Além dos aspectos organizacionais, Speck [8] ressalta que os mecanismos de financiamento político possuem impacto relevante sobre transparência institucional, responsabilização pública (*accountability*) e riscos associados à corrupção política, reforçando a importância da análise sistemática das informações financeiras disponibilizadas pela Justiça Eleitoral.

Grande parte dos estudos relacionados às finanças partidárias brasileiras concentra-se predominantemente em análises descritivas, institucionais ou exploratórias, com menor ênfase na aplicação formal de métodos inferenciais clássicos da teoria de amostragem. Dessa forma, ainda permanece limitada a utilização de técnicas estatísticas voltadas à redução de variância e melhoria de eficiência inferencial aplicadas a dados eleitorais abertos.

Estudos recentes também destacam o papel crescente das tecnologias analíticas e da ciência de dados aplicadas ao setor público. Sun e Medaglia [13] discutem desafios e oportunidades associados ao uso de inteligência artificial e análise de dados em organizações públicas, evidenciando a importância de estruturas analíticas capazes de apoiar processos de tomada de decisão baseados em evidências.

No âmbito metodológico, técnicas de amostragem, estratificação e utilização de variáveis auxiliares possuem ampla aplicação em problemas caracterizados por elevada heterogeneidade populacional. Os trabalhos clássicos de Cochran [9], Bolfarine e Bussab [12], Lohr [10] e Thompson [11] fornecem a fundamentação estatística para métodos de amostragem estratificada e estimadores auxiliares utilizados neste estudo.

A amostragem aleatória simples apresenta implementação relativamente direta e menor complexidade operacional. Entretanto, sua eficiência tende a diminuir em populações caracterizadas por elevada dispersão estatística, como observado nas finanças partidárias brasileiras. Nesses cenários, abordagens estratificadas podem produzir estimativas mais precisas ao reduzir a variabilidade interna dos grupos analisados [9], [10].

Por outro lado, métodos estratificados dependem da definição adequada dos estratos populacionais. Estratificações inadequadas ou excessivamente heterogêneas podem reduzir os ganhos esperados de precisão e aumentar a complexidade operacional do processo inferencial.

Estimadores auxiliares também apresentam vantagens e limitações. O uso de variáveis auxiliares pode reduzir sig-

nificativamente a variância das estimativas quando existe correlação relevante com a variável de interesse. Entretanto, ganhos de eficiência tendem a diminuir quando a associação entre as variáveis é fraca ou instável [10].

Além disso, Chapman et al. [14] apresentam o modelo CRISP-DM, amplamente utilizado como referência metodológica para projetos de mineração e análise de dados aplicados a grandes volumes de informações. O modelo enfatiza etapas de compreensão dos dados, preparação analítica e avaliação dos resultados, características relevantes para pesquisas baseadas em dados governamentais abertos.

Apesar da crescente disponibilidade de dados financeiros partidários em formatos abertos, ainda são escassos os estudos que exploram conjuntamente:

- heterogeneidade financeira partidária;
- estratificação por porte econômico;
- utilização de estimadores baseados em variáveis auxiliares;
- análise inferencial aplicada a dados eleitorais abertos;
- integração entre estatística amostral e pipelines analíticos reprodutíveis.

Nesse contexto, este trabalho busca contribuir para a literatura ao integrar métodos clássicos de inferência estatística, dados abertos eleitorais e análise financeira partidária em uma estrutura analítica reprodutível voltada à estimação de despesas administrativas dos partidos políticos brasileiros.

IV. DESENVOLVIMENTO

A. Caracterização da Pesquisa

Este trabalho caracteriza-se como uma pesquisa quantitativa, aplicada e exploratória, voltada à comparação de técnicas de amostragem e estimação utilizando dados financeiros de partidos políticos brasileiros. O estudo possui como objetivo avaliar ganhos de precisão obtidos por meio da amostragem estratificada proporcional e do uso de estimadores auxiliares aplicados a indicadores financeiros partidários derivados das bases abertas disponibilizadas pelo Tribunal Superior Eleitoral (TSE).

A pesquisa também apresenta caráter exploratório ao utilizar técnicas de análise descritiva e agrupamento para identificação de padrões financeiros entre partidos políticos com diferentes portes econômicos. Adicionalmente, informações econômicas associadas à Classificação Nacional de Atividades Econômicas (CNAE) foram incorporadas ao processo analítico como mecanismo complementar de enriquecimento exploratório dos dados relacionados a fornecedores e prestadores de serviço vinculados às despesas partidárias.

B. Fontes de Dados e Coleta

O estudo utiliza bases abertas disponibilizadas pelo Tribunal Superior Eleitoral (TSE), especificamente:

- receitas anuais partidárias;
- despesas anuais partidárias.

As bases correspondem às prestações de contas anuais partidárias referentes ao exercício de 2025 [2]–[4].

Informações auxiliares do Cadastro Nacional da Pessoa Jurídica (CNPJ) e da Classificação Nacional de Atividades Econômicas (CNAE) também foram incorporadas ao pipeline analítico para enriquecimento dos dados relacionados a fornecedores e doadores. Os dados de CNAE foram utilizados principalmente para auxiliar análises exploratórias voltadas à identificação de padrões econômicos associados às despesas administrativas partidárias.

As bases do TSE possuem granularidade transacional, em que cada registro representa uma operação financeira individual. Os registros de receita correspondem a arrecadações ou transferências declaradas pelos partidos políticos, enquanto os registros de despesa representam pagamentos ou obrigações financeiras registradas nas prestações de contas partidárias.

TABLE I
RESUMO DAS BASES DE DADOS UTILIZADAS NA PESQUISA

Base	Origem	Descrição
Receitas Partidárias	TSE	Registros de arrecadação
Despesas Partidárias	TSE	Registros de gastos
CNPJ	Receita Federal	Dados cadastrais
CNAE	IBGE	Dados atividade econômica

C. População, Universo e Unidade Amostral

A população de interesse é composta pelos partidos políticos brasileiros com registros financeiros disponíveis nas bases do TSE referentes ao exercício de 2025.

Para fins inferenciais, adotou-se como unidade amostral básica o partido político agregado no nível anual de observação, permitindo consolidar receitas e despesas partidárias em uma única unidade analítica associada a cada legenda, conforme representado por:

$$\text{Partido Político} \times \text{Ano} \quad (4)$$

Esse nível de agregação foi escolhido para reduzir a variabilidade transacional presente nos registros individuais de receitas e despesas e possibilitar a construção de indicadores financeiros padronizados adequados à inferência estatística.

TABLE II
CARACTERÍSTICAS GERAIS DA POPULAÇÃO ANALISADA

Indicador	Valor
Quantidade de partidos	XX
Total de registros de receita	XX
Total de registros de despesa	XX
Total movimentado (R\$)	XX
Coefficiente de variação	XX

D. Variáveis da Pesquisa

A principal variável de interesse corresponde à despesa administrativa total de cada partido político, definida por:

$$Y = \sum_{i=1}^n y_i \quad (5)$$

em que y_i representa cada despesa administrativa registrada para determinado partido político no exercício analisado.

As despesas administrativas foram identificadas a partir de um processo de classificação financeira aplicado às descrições de gastos disponibilizadas pelo TSE. Despesas relacionadas à manutenção operacional, pessoal, infraestrutura, serviços contábeis, serviços jurídicos e demais gastos administrativos recorrentes foram classificadas como administrativas.

A variável auxiliar utilizada corresponde à receita total declarada por cada partido político:

$$X = \sum_{i=1}^n x_i \quad (6)$$

em que x_i representa cada registro de receita associado ao partido político analisado.

A utilização da receita total como variável auxiliar fundamenta-se na expectativa de correlação positiva entre arrecadação e despesas administrativas, hipótese representada por:

$$\rho_{XY} > 0 \quad (7)$$

em que ρ_{XY} representa a correlação entre receita total e despesa administrativa total.

TABLE III
VARIÁVEIS UTILIZADAS NA ANÁLISE ESTATÍSTICA

Variável	Tipo	Descrição
Despesa Administrativa	Dependente	Total de gastos administrativos
Receita Total	Auxiliar	Total arrecadado pelo partido
Porte Financeiro	Derivada	Faixa de arrecadação
CNAE Fornecedor	Exploratória	Atividade econômica predominante

E. Pré-processamento e Tratamento dos Dados

O pipeline analítico foi implementado em Python para ingestão, pré-processamento, enriquecimento e persistência analítica dos dados.

Durante o desenvolvimento do pipeline, ferramentas baseadas em inteligência artificial generativa foram utilizadas como apoio complementar na codificação de funções auxiliares em Python, revisão de trechos de código, geração inicial de estruturas analíticas. O uso dessas ferramentas ocorreu de forma supervisionada, sendo todas as transformações, regras de negócio e análises estatísticas revisadas e validadas manualmente.

As principais etapas de tratamento incluíram:

- padronização textual;
- normalização monetária;
- tratamento de valores nulos;
- parsing de datas;
- padronização de colunas;
- normalização de CNPJ;
- integração de dados auxiliares de CNAE;
- classificação financeira das despesas;
- construção de variáveis derivadas.

As bases processadas foram persistidas em arquivos parquet organizados em camadas analíticas inspiradas na arquitetura medallion [15]:

- raw;
- bronze;
- silver;
- gold.

Os conjuntos analíticos finais foram agregados em indicadores partidários contendo métricas de receita, despesa, percentual de despesas administrativas e demais variáveis relevantes para análise estatística.

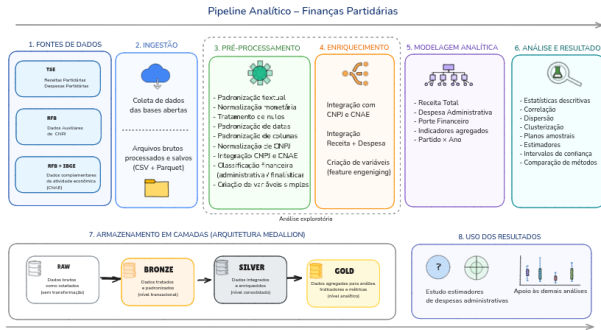


Fig. 1. Fluxo do pipeline analítico desenvolvido para processamento dos dados partidários.

F. Estratégia de Estratificação

Considerando a elevada heterogeneidade financeira observada entre os partidos políticos, foram adotadas estratégias de estratificação com o objetivo de reduzir a variabilidade interna dos grupos e aumentar a precisão das estimativas.

A estratificação foi realizada com base em características financeiras como:

- receita total partidária;
- magnitude das despesas;
- porte financeiro.

Adicionalmente, técnicas exploratórias de agrupamento (*clustering*) foram utilizadas para identificação de padrões financeiros entre partidos políticos com características semelhantes.

G. Planos Amostrais e Estimadores

Os seguintes planos amostrais foram comparados:

- Amostragem Aleatória Simples (AAS);
- Amostragem Estratificada Proporcional.

A comparação entre os métodos busca verificar se a estratificação e o uso de variável auxiliar produzem ganhos de eficiência inferencial em relação à amostragem aleatória simples.

O estimador da média simples é definido por:

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i \quad (8)$$

imagens/distribuicao_receitas.png

Fig. 2. Distribuição da receita total dos partidos políticos.

imagens/clusterizacao_partidos.png

Fig. 3. Agrupamentos financeiros identificados entre partidos políticos.

O estimador razão foi utilizado incorporando a variável auxiliar receita total:

$$\hat{Y}_R = X \frac{\bar{y}}{\bar{x}} \quad (9)$$

A comparação entre os métodos concentrou-se em métricas de eficiência inferencial, incluindo:

- variância;
- erro padrão;
- coeficiente de variação;
- intervalo de confiança;

- erro relativo de estimação.

TABLE IV
COMPARAÇÃO ENTRE OS PLANOS AMOSTRAIS E ESTIMADORES

Método	Variância	Erro	CV	Amplitude IC
AAS	XX	XX	XX	XX
Estratificada	XX	XX	XX	XX
Razão	XX	XX	XX	XX

H. Procedimentos de Análise Estatística

As análises estatísticas exploratórias e inferenciais foram realizadas utilizando Python e Jamovi [16].

O processo analítico incluiu:

- estatísticas descritivas;
- análise de correlação;
- análise de dispersão;
- comparação de variâncias;
- estimação de intervalos de confiança;
- avaliação comparativa entre estimadores.



Fig. 4. Dispersão entre receita total e despesa administrativa dos partidos políticos.

TABLE V
MATRIZ DE CORRELAÇÃO DAS VARIÁVEIS ANALISADAS

Variáveis	Correlação	p-valor
Receita x Despesa	XX	XX

A análise final busca identificar quais estratégias amostrais apresentam maior eficiência estatística na estimação das despesas administrativas partidárias em cenários caracterizados por elevada heterogeneidade financeira.

V. RESULTADOS

A. Análise Exploratória Inicial

As análises exploratórias iniciais evidenciaram elevada heterogeneidade financeira entre os partidos políticos presentes na base do Tribunal Superior Eleitoral (TSE). Observou-se forte assimetria na distribuição das receitas e despesas partidárias, com concentração significativa dos recursos financeiros em um pequeno conjunto de partidos de maior porte.

A Tabela VI apresenta métricas descritivas preliminares da base analítica construída para o exercício de 2025.

TABLE VI
MÉTRICAS DESCRITIVAS PRELIMINARES DA BASE FINANCEIRA PARTIDÁRIA

Métrica	Valor
Quantidade de partidos	XX
Total de receitas (R\$)	XX
Total de despesas (R\$)	XX
Média da despesa administrativa (R\$)	XX
Desvio padrão da despesa (R\$)	XX
Coefficiente de variação	XX

Os resultados preliminares sugerem elevada dispersão das despesas administrativas entre os partidos políticos analisados. O coeficiente de variação observado indica forte heterogeneidade populacional, característica que reforça a adequação do uso de técnicas de estratificação para redução da variância das estimativas.

B. Correlação entre Receita e Despesa Administrativa

A análise de correlação entre receita total partidária e despesa administrativa total indicou associação positiva entre as variáveis, sugerindo que partidos com maior capacidade de arrecadação tendem a apresentar estruturas administrativas proporcionalmente maiores.

A Figura 5 apresenta o comportamento preliminar da relação entre as variáveis analisadas.

A existência de correlação positiva entre as variáveis fornece suporte metodológico para utilização de estimadores auxiliares do tipo razão e regressão.

C. Resultados da Estratificação

A estratificação baseada no porte financeiro dos partidos apresentou redução da variabilidade interna dos grupos quando comparada à população agregada. Os estratos financeiros permitiram separar partidos com características econômicas semelhantes, reduzindo a dispersão das estimativas dentro de cada grupo.

A Tabela VII apresenta um exemplo simplificado da distribuição dos partidos por estrato financeiro.

Os resultados iniciais indicam que a estratificação financeira tende a produzir grupos mais homogêneos, favorecendo ganhos de precisão na estimação das despesas administrativas.

images/scatter_receita_despesa.png

Fig. 5. Relação entre receita total e despesa administrativa

TABLE VII
DISTRIBUIÇÃO PRELIMINAR DOS ESTRATOS FINANCEIROS

Estrato	Partidos	Receita Média (R\$)
Pequeno Porte	XX	XX
Médio Porte	XX	XX
Grande Porte	XX	XX

D. Comparação entre Planos Amostrais

Foram avaliados diferentes planos amostrais, incluindo:

- Amostragem Aleatória Simples (AAS);
- Amostragem Estratificada Proporcional;
- Alocação Ótima de Neyman.

As estimativas obtidas foram comparadas em termos de:

- variância;
- erro padrão;
- coeficiente de variação;
- amplitude dos intervalos de confiança.

A Tabela VIII apresenta um modelo preliminar para comparação dos resultados obtidos.

TABLE VIII
COMPARAÇÃO PRELIMINAR ENTRE ESTRATÉGIAS AMOSTRAIS

Método	Variância	Erro Padrão
AAS	XX	XX
Estratificada Proporcional	XX	XX
Neyman	XX	XX

Os resultados preliminares sugerem que os métodos estratificados apresentaram redução da variância em relação à amostragem aleatória simples, especialmente nos cenários caracterizados por maior heterogeneidade financeira.

E. Avaliação dos Estimadores Auxiliares

Além dos planos amostrais, foram avaliados diferentes estimadores para estimação da despesa administrativa total dos partidos políticos.

Os principais métodos analisados incluem:

- estimador média simples;
- estimador razão;
- estimador regressão.

A utilização da receita total partidária como variável auxiliar contribuiu para melhoria da eficiência inferencial dos estimadores auxiliares. Em particular, os resultados iniciais indicam potencial redução do erro de estimação quando comparados ao estimador baseado exclusivamente na média amostral.

F. Discussão dos Resultados

Os resultados preliminares reforçam a hipótese de que a heterogeneidade financeira dos partidos políticos brasileiros favorece a aplicação de técnicas de estratificação e estimadores auxiliares.

A presença de elevada dispersão populacional, associada à correlação positiva entre arrecadação e despesas administrativas, sugere que métodos inferenciais mais sofisticados podem produzir ganhos relevantes de precisão em comparação com abordagens tradicionais de amostragem aleatória simples.

Além disso, os resultados demonstram a viabilidade da utilização de dados abertos do TSE em estudos quantitativos aplicados à inferência estatística, transparência pública e análise financeira partidária.

VI. CONCLUSION

It is worth noting that in the 2024 database, we had 20.2 million non-litigated registrations and 615.6 thousand litigated ones, representing 97.1% and 2.9%, respectively.

We submitted the 615.6 thousand debts that were not initially litigated but were directed for litigation in 2024 to the model, with the objective of measuring the impact—specifically, how many registrations (that were actually litigated) would be identified by the constructed model. Of the 615.6 thousand debts submitted to the model using joblib's predict function, 550,106 were correctly classified as 1, meaning they would proceed to litigation, while according to the model, 65,520 would not enter non-compliance. Thus, the model would correctly classify 89.35% of the litigated registrations.

Finally, we can say that if each registration, according to the 2011 IPEA study, has a cost of R\$5,606.67, the model resulting from this work would help reduce litigation costs in the year 2024 from R\$3.5 billion to R\$367.3 million, generating a savings of just over R\$3 billion for public coffers.

Another satisfactory point of this study is that each DAU registration that goes into litigation has an average processing time of almost 10 years. That is, identifying such registrations in advance could enable the institution and the debtor to establish a payment agreement, ensuring that the debt is settled within the same 10-year period.

The results of this study may significantly contribute to optimizing the performance of the PGFN in predicting which registrations are likely to proceed to litigation.

As suggestions for future research, we recommend exploring variables not included in the current analysis, testing alternative machine learning algorithms, and even developing specific models for FGTS, social security debts, and other tax obligations. This would involve creating three distinct models with the aim of investigating potential improvements in predictive performance.

REFERENCES

- [1] Tribunal Superior Eleitoral, “Portal de dados abertos do tribunal superior eleitoral,” <https://dadosabertos.tse.jus.br/>, 2025, acesso em: 22 Mar 2026.
- [2] —, “Prestação de contas anual partidária 2025,” <https://dadosabertos.tse.jus.br/dataset/prestacao-de-contas-partidarias-2025>, 2025, base de receitas e despesas partidárias utilizada no estudo.
- [3] —, “receita_anual_2025_BRASIL.csv,” <https://dadosabertos.tse.jus.br/dataset/prestacao-de-contas-partidarias-2025>, 2025, arquivo de receitas partidárias utilizado na pesquisa.
- [4] —, “despesa_anual_2025_brasil.csv,” <https://dadosabertos.tse.jus.br/dataset/prestacao-de-contas-partidarias-2025>, 2025, arquivo de despesas partidárias utilizado na pesquisa.
- [5] Brasil, “Lei nº 12.527, de 18 de novembro de 2011. regula o acesso a informações previsto no art. 5º, da constituição federal,” 2011. [Online]. Available: <https://planalto.gov.br>
- [6] B. Bolognesi and E. U. Cervi, “O perfil do financiamento dos partidos brasileiros (2006-2012): autores, objetivos, êxito e fracasso,” *Revista Brasileira de Ciência Política*, no. 23, pp. 71–96, 2018. [Online]. Available: <http://repositorio.unb.br/handle/10482/29679>
- [7] M. d. S. S. Braga and A. Bourdoukan, “Partidos políticos no brasil: organização partidária, competição eleitoral e financiamento público,” *Perspectivas*, vol. 35, pp. 117–148, 2009, artigo disponível em PDF no portal da UNESP. [Online]. Available: <https://periodicos.fclar.unesp.br/perspectivas/article/view/2290/1858>
- [8] B. W. Speck, “O financiamento político e a corrupção no brasil,” in *Temas de corrupção política no Brasil*, R. d. C. Biason, Ed. São Paulo: Balão Editorial, 2012, pp. 49–97, acesso via Academia.edu. [Online]. Available: https://www.academia.edu/3556070/Bruno_Wilhelm_Speck_O_financiamento_pol%C3%ADtico_e_a_corrup%C3%A7%C3%A3o_no_Brasil
- [9] W. G. Cochran, *Sampling Techniques*, 3rd ed. New York: John Wiley & Sons, 1977.
- [10] S. L. Lohr, *Sampling: Design and Analysis*, 2nd ed. Boston: Brooks/Cole, 2010.
- [11] S. K. Thompson, *Sampling*, 3rd ed. Hoboken: John Wiley & Sons, 2012.
- [12] H. Bolfarine and W. d. O. Bussab, *Elementos de Amostragem*. São Paulo: Edgard Blücher, 2005.
- [13] T. Q. Sun and R. Medaglia, “Mapping the challenges of artificial intelligence in the public sector: Evidence from public healthcare,” *Government Information Quarterly*, vol. 36, no. 2, pp. 368–383, 2019. [Online]. Available: <https://doi.org/10.1016/j.giq.2018.09.008>
- [14] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, “Crisp-dm 1.0: Step-by-step data mining guide,” 2000.
- [15] M. Armbrust, A. Ghodsi, R. Xin, and M. Zaharia, “Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics,” in *CIDR ’21: Conference on Innovative Data Systems Research*, 2021. [Online]. Available: https://www.cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf
- [16] The jamovi Project, “jamovi,” 2025. [Online]. Available: <https://www.jamovi.org>